

Énoncé – Exercice pratique : Data Lake vs Data Warehouse (version locale)

Contexte :

Votre entreprise collecte des données de ventes journalières sous forme de fichiers CSV déposés dans un dossier local.

Vous devez analyser ces données en adoptant deux approches distinctes :

1. **Approche Data Lake** : stockage brut sans transformation préalable.
2. **Approche Data Warehouse** : structuration et chargement dans une base relationnelle locale.

Objectifs pédagogiques :

- Comprendre la différence entre **stockage brut (Data Lake)** et **stockage structuré (Data Warehouse)**.
- Manipuler des fichiers de données réelles (CSV).
- Effectuer des opérations de transformation minimale.
- Charger et interroger une base relationnelle.

Instructions :

Étape 1 – Mise en place du "Data Lake" local

1. Crée un dossier `data_lake/` avec la structure suivante :

```
data_lake/  
├── raw/  
├── transformed/  
└── analytics/
```

2. Dans `data_lake/raw/`, place un fichier `ventes_2024.csv` contenant :

```
Date,Client,Produit,Quantite,PrixUnitaire  
2024-01-01,Jean,PC,2,1200  
2024-01-02,Marie,Téléphone,1,700  
2024-01-03,Paul,Écran,3,300
```

Étape 2 – Simulation d'un Data Warehouse local

1. Installe ou utilise un moteur de base relationnelle local : **PostgreSQL**, **SQLite** ou **autre**.

2. Crée une base nommée `entreprise_dw`.
3. Crée une table `ventes` avec la structure suivante :

```
CREATE TABLE ventes (  
    id SERIAL PRIMARY KEY,  
    date DATE,  
    client TEXT,  
    produit TEXT,  
    quantite INT,  
    prix_unitaire NUMERIC,  
    total NUMERIC  
);
```

4. Écris un petit script Python (ou utilise un outil ETL) pour :
 - Lire le fichier CSV depuis `data_lake/raw/`
 - Calculer une colonne `total = quantite × prix_unitaire`
 - Charger les données dans la base `entreprise_dw` dans la table `ventes`

Étape 3 – Analyse et réflexion

1. Compare les deux approches (Data Lake vs Data Warehouse) à travers ces questions :
 - Quels types de requêtes sont faciles ou difficiles à faire dans chaque approche ?
 - Quel est le niveau de structuration des données dans chaque cas ?
 - Quelles sont les implications en termes de gouvernance, qualité, et sécurité ?

Livrables attendus

- Affichage de la table `ventes` remplie.
- Réponses à la comparaison Data Lake vs Data Warehouse.
- Scripts utilisés pour le traitement.